

Score File Inventory

Total files: 14701, claimed: 9955, unclaimed: 4746, configs complete: 198/735

gemma-2-2b

plausibleqa (100 tasks)

Train	Variant	neg	self	gpt2
base	base	100/100	100/100	99/100
plain	comb lo	100/100	100/100	0/100
plain	comb semi	100/100	100/100	0/100
plain	pref-only lo	100/100	100/100	0/100
plain	pref-only semi	100/100	100/100	0/100
plain	pref-only vlo lo	100/100	100/100	0/100
plain	sft lo	0/100	100/100	0/100
plain	sft semi	100/100	100/100	0/100
tc-neg	comb lo	100/100	0/100	0/100
tc-neg	comb semi	100/100	0/100	0/100
tc-neg	pref-only lo	100/100	0/100	0/100
tc-neg	pref-only semi	100/100	0/100	0/100
tc-neg	pref-only vlo lo	100/100	0/100	0/100
tc-neg	sft lo	0/100	0/100	0/100
tc-neg	sft semi	100/100	0/100	0/100
tc-neg-lenorm	comb lo	0/100	0/100	0/100
tc-neg-lenorm	comb semi	0/100	0/100	0/100
tc-neg-lenorm	pref-only lo	0/100	0/100	0/100
tc-neg-lenorm	pref-only semi	0/100	0/100	0/100
tc-neg-lenorm	pref-only vlo lo	0/100	0/100	0/100
tc-neg-lenorm	sft lo	0/100	0/100	0/100
tc-neg-lenorm	sft semi	0/100	0/100	0/100
tc-self	comb lo	0/100	100/100	0/100
tc-self	comb semi	0/100	100/100	0/100
tc-self	pref-only lo	0/100	100/100	0/100
tc-self	pref-only semi	0/100	100/100	0/100
tc-self	pref-only vlo lo	0/100	100/100	0/100
tc-self	sft lo	0/100	0/100	0/100
tc-self	sft semi	0/100	100/100	0/100
v2g	V2G baseline	100/100	100/100	0/100

ambigqa (17 tasks)

Train	Variant	neg	self	gpt2
base	base	17/17	17/17	17/17
plain	comb lo	17/17	17/17	0/17
plain	comb semi	17/17	17/17	0/17
plain	pref-only lo	17/17	17/17	0/17
plain	pref-only semi	17/17	17/17	0/17
plain	pref-only vlo lo	17/17	17/17	0/17
plain	sft lo	0/17	17/17	0/17
plain	sft semi	17/17	17/17	0/17
tc-neg	comb lo	17/17	0/17	0/17
tc-neg	comb semi	17/17	0/17	0/17
tc-neg	pref-only lo	17/17	0/17	0/17
tc-neg	pref-only semi	17/17	0/17	0/17
tc-neg	pref-only vlo lo	17/17	0/17	0/17
tc-neg	sft lo	0/17	0/17	0/17
tc-neg	sft semi	17/17	0/17	0/17
tc-neg-lenorm	comb lo	0/17	0/17	0/17
tc-neg-lenorm	comb semi	0/17	0/17	0/17
tc-neg-lenorm	pref-only lo	0/17	0/17	0/17
tc-neg-lenorm	pref-only semi	0/17	0/17	0/17
tc-neg-lenorm	pref-only vlo lo	0/17	0/17	0/17
tc-neg-lenorm	sft lo	0/17	0/17	0/17
tc-neg-lenorm	sft semi	0/17	0/17	0/17
tc-self	comb lo	0/17	17/17	0/17
tc-self	comb semi	0/17	17/17	0/17
tc-self	pref-only lo	0/17	17/17	0/17
tc-self	pref-only semi	0/17	17/17	0/17
tc-self	pref-only vlo lo	0/17	17/17	0/17
tc-self	sft lo	0/17	0/17	0/17
tc-self	sft semi	0/17	17/17	0/17
v2g	V2G baseline	17/17	17/17	0/17

hypernym (18 tasks)

Train	Variant	neg	self	gpt2
base	base	18/18	18/18	15/18
plain	comb lo	18/18	18/18	0/18
plain	comb semi	18/18	18/18	0/18
plain	pref-only lo	18/18	18/18	0/18
plain	pref-only semi	18/18	18/18	0/18
plain	pref-only vlo lo	18/18	18/18	0/18
plain	sft lo	0/18	18/18	0/18
plain	sft semi	18/18	18/18	0/18
tc-neg	comb lo	18/18	0/18	0/18
tc-neg	comb semi	18/18	0/18	0/18
tc-neg	pref-only lo	18/18	0/18	0/18
tc-neg	pref-only semi	18/18	0/18	0/18
tc-neg	pref-only vlo lo	18/18	0/18	0/18
tc-neg	sft lo	0/18	0/18	0/18
tc-neg	sft semi	18/18	0/18	0/18
tc-neg-lenorm	comb lo	0/18	0/18	0/18
tc-neg-lenorm	comb semi	0/18	0/18	0/18
tc-neg-lenorm	pref-only lo	0/18	0/18	0/18
tc-neg-lenorm	pref-only semi	0/18	0/18	0/18
tc-neg-lenorm	pref-only vlo lo	0/18	0/18	0/18
tc-neg-lenorm	sft lo	0/18	0/18	0/18
tc-neg-lenorm	sft semi	0/18	0/18	0/18
tc-self	comb lo	0/18	18/18	0/18
tc-self	comb semi	0/18	18/18	0/18
tc-self	pref-only lo	0/18	18/18	0/18
tc-self	pref-only semi	0/18	18/18	0/18
tc-self	pref-only vlo lo	0/18	18/18	0/18
tc-self	sft lo	0/18	0/18	0/18
tc-self	sft semi	0/18	18/18	0/18
v2g	V2G baseline	18/18	18/18	0/18

gemma-2-9b-it**plausibleqa (100 tasks)**

Train	Variant	neg	self	gpt2
base	base	100/100	100/100	0/100
plain	comb lo	100/100	100/100	0/100
plain	comb semi	100/100	100/100	0/100
plain	pref-only lo	100/100	100/100	0/100
plain	pref-only semi	100/100	100/100	0/100
plain	pref-only vlo lo	100/100	0/100	0/100
plain	sft lo	0/100	100/100	0/100
plain	sft semi	100/100	100/100	0/100
tc-neg	comb lo	100/100	0/100	0/100
tc-neg	comb semi	100/100	0/100	0/100
tc-neg	pref-only lo	100/100	0/100	0/100
tc-neg	pref-only semi	100/100	0/100	0/100
tc-neg	pref-only vlo lo	100/100	0/100	0/100
tc-neg	sft lo	0/100	0/100	0/100
tc-neg	sft semi	100/100	0/100	0/100
tc-self	comb lo	0/100	100/100	0/100
tc-self	comb semi	0/100	100/100	0/100
tc-self	pref-only lo	0/100	100/100	0/100
tc-self	pref-only semi	0/100	100/100	0/100
tc-self	pref-only vlo lo	0/100	0/100	0/100
tc-self	sft lo	0/100	0/100	0/100
tc-self	sft semi	0/100	100/100	0/100
v2g	V2G baseline	100/100	100/100	0/100

ambigqa (17 tasks)

Train	Variant	neg	self	gpt2
base	base	17/17	17/17	0/17
plain	comb lo	17/17	17/17	0/17
plain	comb semi	17/17	17/17	0/17
plain	pref-only lo	17/17	17/17	0/17
plain	pref-only semi	17/17	17/17	0/17
plain	pref-only vlo lo	0/17	0/17	0/17
plain	sft lo	0/17	17/17	0/17
plain	sft semi	17/17	17/17	0/17
tc-neg	comb lo	17/17	0/17	0/17
tc-neg	comb semi	17/17	0/17	0/17
tc-neg	pref-only lo	17/17	0/17	0/17
tc-neg	pref-only semi	17/17	0/17	0/17
tc-neg	pref-only vlo lo	17/17	0/17	0/17
tc-neg	sft lo	0/17	0/17	0/17
tc-neg	sft semi	17/17	0/17	0/17
tc-self	comb lo	0/17	17/17	0/17
tc-self	comb semi	0/17	17/17	0/17
tc-self	pref-only lo	0/17	17/17	0/17
tc-self	pref-only semi	0/17	17/17	0/17
tc-self	pref-only vlo lo	0/17	0/17	0/17
tc-self	sft lo	0/17	0/17	0/17
tc-self	sft semi	0/17	17/17	0/17
v2g	V2G baseline	17/17	17/17	0/17

hypernym (18 tasks)

Train	Variant	neg	self	gpt2
base	base	18/18	18/18	0/18
plain	comb lo	18/18	18/18	0/18
plain	comb semi	18/18	18/18	0/18
plain	pref-only lo	18/18	18/18	0/18
plain	pref-only semi	18/18	18/18	0/18
plain	pref-only vlo lo	0/18	0/18	0/18
plain	sft lo	0/18	18/18	0/18
plain	sft semi	18/18	18/18	0/18
tc-neg	comb lo	18/18	0/18	0/18
tc-neg	comb semi	18/18	0/18	0/18
tc-neg	pref-only lo	18/18	0/18	0/18
tc-neg	pref-only semi	18/18	0/18	0/18
tc-neg	pref-only vlo lo	18/18	0/18	0/18
tc-neg	sft lo	0/18	0/18	0/18
tc-neg	sft semi	18/18	0/18	0/18
tc-self	comb lo	0/18	18/18	0/18
tc-self	comb semi	0/18	18/18	0/18
tc-self	pref-only lo	0/18	18/18	0/18
tc-self	pref-only semi	0/18	18/18	0/18
tc-self	pref-only vlo lo	0/18	0/18	0/18
tc-self	sft lo	0/18	0/18	0/18
tc-self	sft semi	0/18	18/18	0/18
v2g	V2G baseline	18/18	18/18	0/18

	Train	Variant	neg	self	gpt2
ifeval (99 tasks)	base	base	99/99	99/99	99/99
	plain	comb lo	99/99	99/99	0/99
	plain	comb semi	99/99	99/99	0/99
	plain	pref-only lo	99/99	99/99	0/99
	plain	pref-only vlo lo	0/99	0/99	0/99
	plain	sft lo	0/99	99/99	0/99
	plain	sft semi	99/99	99/99	0/99
	tc-neg	comb lo	80/99	0/99	0/99
	tc-neg	comb semi	72/99	0/99	0/99
	tc-neg	pref-only lo	79/99	0/99	0/99
	tc-neg	pref-only vlo lo	21/99	0/99	0/99
	tc-neg	sft lo	0/99	0/99	0/99
	tc-neg	sft semi	0/99	0/99	0/99
	tc-self	comb lo	0/99	99/99	0/99
	tc-self	comb semi	0/99	99/99	0/99
	tc-self	pref-only lo	0/99	99/99	0/99
	tc-self	pref-only vlo lo	0/99	0/99	0/99
	tc-self	sft lo	0/99	0/99	0/99
	tc-self	sft semi	0/99	99/99	0/99
	v2g	V2G baseline	0/99	0/99	0/99

Unclaimed files

Category	Count
lenorm evals	1737
tc+lenorm trained models	1176
2b ifeval (excluded)	1023
other	720
gemma-2-2b-it (not tracked)	90
Total	4746